

# Exercicio Regressao Multipla Sala

Davi Wentrick Feijó - 200016806

2023-06-02

## Regressao Linear Multipla

Vamos usar esses dados:

##	Area	Safra de Trigo	Fertilizante	Chuva
## 1	1	40	100	10
## 2	2	38	150	10
## 3	3	50	200	20
## 4	4	49	250	20
## 5	5	50	300	10
## 6	6	55	350	20
## 7	7	70	400	30
## 8	8	55	410	20
## 9	9	45	450	10
## 10	10	65	500	20
## 11	11	72	550	20
## 12	12	70	600	30
## 13	13	65	650	20
## 14	14	80	700	30
## 15	15	75	800	30

```
n <- nrow(dados) # Number of observations
n
```

Especificar os elementos dos vetores e matrizes do problema

```
## [1] 15
```

Nosso Y será a safra de trigo:

```
##      [,1]
## [1,] 40
## [2,] 38
## [3,] 50
## [4,] 49
## [5,] 50
## [6,] 55
## [7,] 70
```

```
## [8,] 55
## [9,] 45
## [10,] 65
## [11,] 72
## [12,] 70
## [13,] 65
## [14,] 80
## [15,] 75
```

E o X será o fertilizante e o indice de chuvas:

```
##      [,1] [,2]
## [1,] 100  10
## [2,] 150  10
## [3,] 200  20
## [4,] 250  20
## [5,] 300  10
## [6,] 350  20
## [7,] 400  30
## [8,] 410  20
## [9,] 450  10
## [10,] 500  20
## [11,] 550  20
## [12,] 600  30
## [13,] 650  20
## [14,] 700  30
## [15,] 800  30
```

podemos adicionar na matriz X o vetor de 1 para ser nosso intecepto.

```
X <- cbind(rep(1,n), X)
X
```

```
##      [,1] [,2] [,3]
## [1,] 1 100  10
## [2,] 1 150  10
## [3,] 1 200  20
## [4,] 1 250  20
## [5,] 1 300  10
## [6,] 1 350  20
## [7,] 1 400  30
## [8,] 1 410  20
## [9,] 1 450  10
## [10,] 1 500  20
## [11,] 1 550  20
## [12,] 1 600  30
## [13,] 1 650  20
## [14,] 1 700  30
## [15,] 1 800  30
```

Vamos definir nossa matriz J que sera com composta inteiramente por 1 e sera  $n \times n$  (n sendo o numero de observacoes)

```
J = matrix(data = 1, nrow = n, ncol = n)
head(J)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12] [,13] [,14]
## [1,]    1    1    1    1    1    1    1    1    1    1    1    1    1    1
## [2,]    1    1    1    1    1    1    1    1    1    1    1    1    1    1
## [3,]    1    1    1    1    1    1    1    1    1    1    1    1    1    1
## [4,]    1    1    1    1    1    1    1    1    1    1    1    1    1    1
## [5,]    1    1    1    1    1    1    1    1    1    1    1    1    1    1
## [6,]    1    1    1    1    1    1    1    1    1    1    1    1    1    1
##      [,15]
## [1,]      1
## [2,]      1
## [3,]      1
## [4,]      1
## [5,]      1
## [6,]      1
```

Agora podemos encontrar nosso vetor de Betas sabendo que ele pode ser calculado da seguinte forma:

$$\beta = (X^T X)^{-1} X^T Y$$

```
#encontrando XTX
```

```
XTX = t(X) %*% X
XTX
```

```
##      [,1] [,2] [,3]
## [1,]   15  6410   300
## [2,] 6410 3343100 143200
## [3,]   300 143200   6800
```

```
#encontrando XTY
```

```
XTY = t(X) %*% Y
XTY
```

```
##      [,1]
## [1,]   879
## [2,] 409350
## [3,] 18800
```

```
#encontrando a inversa de XTX
```

```
XTX_inv = solve(XTX)
XTX_inv
```

```
##      [,1] [,2] [,3]
## [1,] 0.5751552282 -1.622018e-04 -2.195872e-02
## [2,] -0.0001622018  3.099398e-06 -5.811371e-05
## [3,] -0.0219587160 -5.811371e-05  2.339632e-03
```

```
#encontrando a matriz de parametros Beta (ela contem o Beta 0 e o Beta 1 ou todos os beta no caso de u
```

```
beta = XTX_inv %*% t(X) %*% Y #em partes
```

```
beta = solve(t(X) %*% X) %*% t(X) %*% Y #direto
```

```
beta
```

```
##           [,1]  
## [1,] 26.34027254  
## [2,]  0.03362537  
## [3,]  0.89452440
```

Com a matriz de betas podemos ajustar os valores esperados do modelo  $\hat{Y}$ :

```
#valores estimados pelo modelo (y chapau)
```

```
Yhat <- X %*% beta # Fitted Values
```

```
Yhat
```

```
##           [,1]  
## [1,] 38.64805  
## [2,] 40.32932  
## [3,] 50.95583  
## [4,] 52.63710  
## [5,] 45.37313  
## [6,] 55.99964  
## [7,] 66.62615  
## [8,] 58.01716  
## [9,] 50.41693  
## [10,] 61.04344  
## [11,] 62.72471  
## [12,] 73.35122  
## [13,] 66.08725  
## [14,] 76.71376  
## [15,] 80.07630
```

Em seguida podemos calcular nossos residuos

```
#residuos do modelo
```

```
e <- Y - Yhat # Residuals
```

```
e
```

```
##           [,1]  
## [1,]  1.3519469  
## [2,] -2.3293213  
## [3,] -0.9558336  
## [4,] -3.6371019  
## [5,]  4.6268738  
## [6,] -0.9996384  
## [7,]  3.3738493  
## [8,] -3.0171603  
## [9,] -5.4169310
```

```
## [10,] 3.9565568
## [11,] 9.2752885
## [12,] -3.3512237
## [13,] -1.0872480
## [14,] 3.2862397
## [15,] -5.0762968
```

Podemos realizar a ANOVA do modelo para isso precisaremos calcular as seguintes somas de quadrados

- Soma de quadrados da regressao (SSR ou SQR)

$$- \hat{\beta}^T X^T Y - \frac{1}{n} Y^T J Y$$

- Soma de quadrados do residuo (SSE ou SQE)

$$- \epsilon^T \epsilon \text{ ou } Y^T Y - \hat{\beta}^T X^T Y$$

- Soma de quadrados total (SST ou SQT)

$$- SSE + SSR$$

```
sse = t(e) %*% e #soma de quadrados do residuo
sse = t(Y) %*% Y - t(beta) %*% t(X) %*% Y #segunda forma de calcular
sse
```

```
##           [,1]
## [1,] 244.2984
```

```
ssr = t(beta) %*% t(X) %*% Y - (1/n) * (t(Y) %*% J %*% Y) #soma de quadrados da regressao
ssr
```

```
##           [,1]
## [1,] 2225.302
```

```
sst = ssr + sse #soma de quadrados total
sst
```

```
##           [,1]
## [1,] 2469.6
```

Em seguida temos que encontrar os quadrados medios:

- Quadrado Médio da regressao (MSR ou QMR)

$$- \frac{SSR}{p-1}$$

- Quadrado Médio do residuo (MSE ou QME)

$$- \frac{SSE}{n-p}$$

Onde  $n$  é o número de observacoes e  $p$  o número de parametros (variaveis) do modelo

```
p = length(beta)
```

Vamos obter os graus de liberdade da regressão, resíduo e total

```
glreg = p-1  
glres = n-p  
gltot = n-1
```

```
## A quantidade de graus de liberdade relacionado a regressão é: 2
```

```
## A quantidade de graus de liberdade relacionado aos resíduos é: 12
```

```
## A quantidade de graus de liberdade relacionado ao total é: 14
```

```
msr = ssr/(p-1)  
msr
```

```
##           [,1]  
## [1,] 1112.651
```

```
mse = sse/(n-p)  
mse
```

```
##           [,1]  
## [1,] 20.3582
```

Vamos calcular nosso  $R^2$ :

```
r2 = ssr / sst  
r2
```

```
##           [,1]  
## [1,] 0.9010777
```

Vamos calcular a soma de quadrados extra, para isso vamos ajustar um modelo somente com a variável fertilizante e ver quanto ela explica por si só e quanto que adicionar a variável chuva vai incrementar nessa explicação. Para agilizar vamos calcular usando o a função `lm()`

```
modelo_1 = lm(safra_de_trigo ~ fertilizante ,data = dados)  
ssr1 <- sum((fitted(modelo_1) - mean(dados$safra_de_trigo))^2)  
  
ssrx1x2 = ssr - ssr1
```

Em seguida podemos calcular os valores F observados:

```
f_value_reg = msr/mse  
f_value_reg
```

```
##           [,1]  
## [1,] 54.65369
```

```
f_value_x1 = ssr1/mse
f_value_x1
```

```
##           [,1]
## [1,] 92.50784
```

```
f_value_x1x2 = ssrx1x2/mse
f_value_x1x2
```

```
##           [,1]
## [1,] 16.79954
```

Vamos calcular os p-valores do teste F

Podemos apresentar nossa tabela da anova

```
## Fonte_de_variacao GL      SS      MQ F_Value
## 1      Regressao  2 2225.3016 1112.65   54.65
## 2           X1   1 1883.2931 1883.29   92.51
## 3      X1|X2   1   342.0084  342.01    16.8
## 4      Residuos 12   244.2984   20.36
## 5          Total 14 2469.6000
```

Vamos comparar com a anova do R:

```
modelo_completo = lm(safra_de_trigo ~ fertilizante + chuva ,data = dados)
anova(modelo_completo)
```

```
## Analysis of Variance Table
##
## Response: safra_de_trigo
##           Df Sum Sq Mean Sq F value    Pr(>F)
## fertilizante  1 1883.29 1883.29  92.508 5.446e-07 ***
## chuva         1   342.01  342.01  16.799 0.001476 **
## Residuals    12   244.30   20.36
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```