

Lista 1 B

Davi Wentrick Feijó

2023-04-21

Em um exercício de simulação considerando um modelo de regressão linear simples com parâmetros $\beta_0 = 100$, $\beta_1 = 20$ e $\sigma^2 = 25$, será gerada uma observação de Y para $X = 5$.

a) É possível determinar a probabilidade exata de que será um valor entre 195 e 205? Justifique sua resposta. Não pois não sabemos qual é a distribuição do erro do modelo

b) Se for utilizado um modelo de regressão com erro normal, é possível determinar a probabilidade acima? Caso seja possível, determine seu valor. Justifique sua resposta. Assumindo normalidade nos obtemos a seguinte distribuição dos erros:

$$\epsilon \sim N(\mu, \sigma^2)$$

onde:

$$\mu = \hat{Y} = E(\hat{\beta}_0 + \hat{\beta}_1 \cdot X)$$

Substituindo para $X = 5$ obtemos:

$$\mu = \hat{Y} = E(100 + 20 \cdot 5) = 200$$

Como no exercício foi dado que $\sigma^2 = 25$ chegamos na seguinte distribuição dado $X = 5$:

$$\epsilon \sim N(200, 25)$$

Agora podemos calcular a probabilidade de $X \in [195, 205]$:

Manulamente teríamos que resolver a seguinte conta $P(195 < x < 205)$

$$P(195 < x < 205) = P(x < 205) - (1 - P(x > 195)) = P(x < 205) - P(x < 195)$$

Em seguida teríamos que passar para a normal padrão $N(0, 1)$ e calcular a probabilidade, mas vamos fazer computacionalmente por meio desse código:

```

beta_0 = 100
beta_1 = 20
x_escolhido = 5
sigma_quadrado = 25 #desvio padrao
y_new_hat <- beta_0 + beta_1*x_escolhido #media

#se assumirmos que os erros seguem normalidade podemos
#calcular a partir de uma normal de media 200 e desvio padrao 25

n_value_lower <- pnorm(195, mean = y_new_hat, sd = 25) #P(x<205)
n_value_upper <- pnorm(205, mean = y_new_hat, sd = 25) #P(x<195)

prob = n_value_upper-n_value_lower

```

O valor estimado Y quando X= 5 é: 200

A probabilidade de Y estar entre 195 e 200 é: 0.1585194

Considere um modelo regressivo linear simples. com erro normal. Suponha que os valores dos parâmetros são $\beta_0 = 200$, $\beta_1 = 5$ e $\sigma = 4$

$$Y = 200 + 5X$$

a) Qual a distribuição de probabilidade de Y para $X = 10$? E para $X = 25$? Para $X = 10$:

$$Y = 200 + 5 \cdot 10 = 250$$

$$\hat{Y}|X = 10 \sim N(250, 16)$$

Para $X = 25$:

$$Y = 200 + 5 \cdot 10 = 325$$

$$\hat{Y}|X = 25 \sim N(325, 16)$$

b) Explique o significado dos parâmetros β_0 e β_1 . Suponha que o alcance do modelo inclui $X = 0$. O parâmetro β_0 nos indica onde que a reta toca o eixo Y , já os β_1 indica a taxa de aumento de Y em relação a X . O ponto de $X = 0$ é igual ao β_0

Seja o MRLS $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$, $\forall i = 1, n$ e β_0 e β_1 Seus estimadores:

Prove que:

$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$ Vale lembrar que a $E(C) = C$ caso C seja uma constante

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n E(Y_i)$$

$$\sum_{i=1}^n \beta_0 + \beta_1 \cdot X_i = \sum_{i=1}^n E(\hat{\beta}_0 + \hat{\beta}_1 \cdot X_i)$$

$$\sum_{i=1}^n \beta_0 + \beta_1 \cdot X_i = \sum_{i=1}^n E(\hat{\beta}_0) + E(\hat{\beta}_1 \cdot X_i)$$

$$\sum_{i=1}^n \beta_0 + \beta_1 \cdot X_i = \sum_{i=1}^n \hat{\beta}_0 + \hat{\beta}_1 \cdot E(X_i)$$

$$\sum_{i=1}^n \beta_0 + \beta_1 \cdot X_i = \sum_{i=1}^n \hat{\beta}_0 + \hat{\beta}_1 \cdot X_i$$

Como $\hat{\beta}_0$ e $\hat{\beta}_1$ são estimadores de β_0 e β_1 então você tem os mesmos elementos de cada lado!

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$$

$\sum_{i=1}^n e_i = 0$ **onde** $e_i = Y_i - \hat{Y}_i$ Utilizando do resultado que encontramos anteriormente temos:

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$$

$$\sum_{i=1}^n Y_i - \sum_{i=1}^n \hat{Y}_i = 0$$

$$\sum_{i=1}^n Y_i - \hat{Y}_i = 0$$

$$\sum_{i=1}^n e_i = 0$$

A reta de regressão estimada passa pelo centro de gravidade (\bar{X}, \bar{Y}) no diagrama de dispersão (X_i, Y_i) .

$$(\bar{X}, \bar{Y}) = (E(X_i), E(Y_i)) = (X_i, E(\hat{\beta}_0 + \hat{\beta}_1 \cdot X_i))$$

$$(X_i, E(\hat{\beta}_0) + E(\hat{\beta}_1 \cdot X_i)) = (X_i, \hat{\beta}_0 + \hat{\beta}_1 \cdot E(X_i))$$

$$(X_i, E(\hat{\beta}_0) + E(\hat{\beta}_1 \cdot X_i)) = (X_i, \hat{\beta}_0 + \hat{\beta}_1 \cdot X_i) = (X_i, Y_i)$$

- verificar esse resultado nao sei se está certo -

$$\sum_{i=1}^n X_i \cdot e_i = 0$$

$$\sum_{i=1}^n X_i \cdot e_i = 0$$

$$\sum_{i=1}^n X_i \cdot (Y_i - \hat{Y}_i) = 0$$

$$\sum_{i=1}^n (X_i Y_i - X_i \hat{Y}_i) = 0$$

$$\sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \hat{Y}_i = 0$$

$$\sum_{i=1}^n X_i (\beta_0 + \beta_1 \cdot X_i) - \sum_{i=1}^n X_i (\hat{\beta}_0 + \hat{\beta}_1 \cdot X_i) = 0$$

$$\sum_{i=1}^n X_i \beta_0 + X_i \beta_1 \cdot X_i - \sum_{i=1}^n (X_i \hat{\beta}_0 + X_i \hat{\beta}_1 \cdot X_i) = 0$$

$$\sum_{i=1}^n X_i \beta_0 + X_i^2 \beta_1 - \sum_{i=1}^n X_i \hat{\beta}_0 + X_i^2 \hat{\beta}_1 = 0$$

$$\sum_{i=1}^n X_i \beta_0 + \sum_{i=1}^n X_i^2 \beta_1 - \sum_{i=1}^n X_i \hat{\beta}_0 + \sum_{i=1}^n X_i^2 \hat{\beta}_1 = 0$$

Como $\hat{\beta}_0$ e $\hat{\beta}_1$ são estimadores de β_0 e β_1 então você pode reorganizar a conta para ter os mesmos elementos de cada lado!

$$\sum_{i=1}^n X_i \beta_0 + \sum_{i=1}^n X_i^2 \beta_1 = \sum_{i=1}^n X_i \hat{\beta}_0 + \sum_{i=1}^n X_i^2 \hat{\beta}_1$$

Logo:

$$\sum_{i=1}^n X_i \beta_0 + \sum_{i=1}^n X_i^2 \beta_1 = \sum_{i=1}^n X_i \hat{\beta}_0 + \sum_{i=1}^n X_i^2 \hat{\beta}_1$$

$$\sum_{i=1}^n X_i Y_i = \sum_{i=1}^n X_i \hat{Y}_i$$

$$\sum_{i=1}^n Y_i \cdot e_i = 0$$

$$\sum_{i=1}^n Y_i \cdot e_i = 0$$

$$\sum_{i=1}^n Y_i \cdot (Y_i - \hat{Y}_i) = 0$$

$$\sum_{i=1}^n Y_i Y_i - Y_i \hat{Y}_i = 0$$

$$\sum_{i=1}^n Y_i^2 - Y_i \hat{Y}_i = 0$$

$$\sum_{i=1}^n Y_i^2 - (\beta_0 + \beta_1 \cdot X_i)(\hat{\beta}_0 + \hat{\beta}_1 \cdot X_i) = 0$$

$$\sum_{i=1}^n Y_i^2 - (\hat{\beta}_0 \beta_0 + \beta_0 \hat{\beta}_1 X_i + \hat{\beta}_0 \beta_1 X_i + \beta_1 X_i \hat{\beta}_1 X_i) = 0$$

Como $\hat{\beta}_0$ e $\hat{\beta}_1$ são estimadores de β_0 e β_1 então você pode reorganizar a conta para ter os mesmos elementos de cada lado!

$$\sum_{i=1}^n Y_i^2 - \sum_{i=1}^n (\beta_0^2 + 2(\beta_0 \beta_1 X_i) + \beta_1^2 X_i^2) = 0$$

$$\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n (\beta_0^2 + 2(\beta_0 \beta_1 X_i) + \beta_1^2 X_i^2)$$

Sabemos que $\beta_0^2 + 2(\beta_0 \beta_1 X_i) + \beta_1^2 X_i^2 = Y_i \hat{Y}_i$

$$\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n Y_i \hat{Y}_i$$