

# Lista 1 B

Davi Wentrick Feijó

2023-04-21

**Em um exercício de simulação considerando um modelo de regressão linear simples com parâmetros  $\beta_0 = 100$ ,  $\beta_1 = 20$  e  $\sigma^2 = 25$ , será gerada uma observação de  $Y$  para  $X = 5$ .**

**a) É possível determinar a probabilidade exata de que será um valor entre 195 e 205? Justifique sua resposta.** Não pois não sabemos qual é a distribuição do erro do modelo

**b) Se for utilizado um modelo de regressão com erro normal, é possível determinar a probabilidade acima? Caso seja possível, determine seu valor. Justifique sua resposta.** Assumindo normalidade nos obtemos a seguinte distribuição dos erros:

$$\epsilon \sim N(\mu, \sigma^2)$$

onde:

$$\mu = \hat{Y} = E(\hat{\beta}_0 + \hat{\beta}_1 \cdot X)$$

Substituindo para  $X = 5$  obtemos:

$$\mu = \hat{Y} = E(100 + 20 \cdot 5) = 200$$

Como no exercício foi dado que  $\sigma^2 = 25$  chegamos na seguinte distribuição dado  $X = 5$ :

$$\epsilon \sim N(200, 25)$$

Agora podemos calcular a probabilidade de  $X \in [195, 205]$ :

Manulamente teríamos que resolver a seguinte conta  $P(195 < x < 205)$

$$P(195 < x < 205) = P(x < 205) - (1 - P(x > 195)) = P(x < 205) - P(x < 195)$$

Em seguida teríamos que passar para a normal padrão  $N(0, 1)$  e calcular a probabilidade, mas vamos fazer computacionalmente por meio desse código:

```

beta_0 = 100
beta_1 = 20
x_escolhido = 5
sigma_quadrado = 25 #desvio padrao
y_new_hat <- beta_0 + beta_1*x_escolhido #media

#se assumirmos que os erros seguem normalidade podemos
#calcular a partir de uma normal de media 200 e desvio padrao 25

n_value_lower <- pnorm(195, mean = y_new_hat, sd = 25) #P(x<205)
n_value_upper <- pnorm(205, mean = y_new_hat, sd = 25) #P(x<195)

prob = n_value_upper-n_value_lower

```

## O valor estimado Y quando X= 5 é: 200

## A probabilidade de Y estar entre 195 e 200 é: 0.1585194

Considere um modelo regressivo linear simples. com erro normal. Suponha que os valores dos parâmetros são  $\beta_0 = 200$ ,  $\beta_1 = 5$  e  $\sigma = 4$

$$Y = 200 + 5X$$

a) Qual a distribuição de probabilidade de  $Y$  para  $X = 10$ ? E para  $X = 25$ ? Para  $X = 10$ :

$$Y = 200 + 5 \cdot 10 = 250$$

$$\hat{Y}|X = 10 \sim N(250, 16)$$

Para  $X = 25$ :

$$Y = 200 + 5 \cdot 25 = 325$$

$$\hat{Y}|X = 25 \sim N(325, 16)$$

b) Explique o significado dos parâmetros  $\beta_0$  e  $\beta_1$ . Suponha que o alcance do modelo inclui  $X = 0$ . O parâmetro  $\beta_0$  nos indica onde que a reta toca o eixo  $Y$ , já os  $\beta_1$  indica a taxa de aumento de  $Y$  em relação a  $X$ . O ponto de  $X = 0$  é igual ao  $\beta_0$

Seja o MRLS  $Y_i = \beta_0 + \beta_1 + X_i + \epsilon_i$ ,  $\forall i = 1, n$  e  $\beta_0$  e  $\beta_1$  Seus estimadores:

Prove que:

$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$  Vale lembrar que a  $E(C) = C$  caso  $C$  seja uma constante

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n E(Y_i)$$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n E(\hat{\beta}_0 + \hat{\beta}_1 \cdot X_i)$$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n E(\hat{\beta}_0) + E(\hat{\beta}_1 \cdot X_i)$$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{\beta}_0 + \hat{\beta}_1 \cdot E(X_i)$$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{\beta}_0 + \hat{\beta}_1 \cdot X_i$$

$\sum_{i=1}^n e_i = 0$  **onde**  $e_i = Y_i - \hat{Y}_i$  Utilizando do resultado que encontramos anteriormente temos:

$$\begin{aligned}\sum_{i=1}^n e_i &= \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) \\ \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) &= \sum_{i=1}^n Y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n X_i\end{aligned}$$

Vale lembrar que  $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$  que pode ser reescrito como:  $\sum_{i=1}^n X_i = n\bar{X}$

$$\begin{aligned}\sum_{i=1}^n Y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n X_i &= n\bar{Y} - n\hat{\beta}_0 - n\hat{\beta}_1 \bar{X} \\ n\bar{Y} - n\hat{\beta}_0 - n\hat{\beta}_1 \bar{X} &= n(\bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{X})\end{aligned}$$

lembrando que  $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$

$$n(\bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{X}) = n(\bar{Y} - (\bar{Y} - \hat{\beta}_1 \bar{X}) - \hat{\beta}_1 \bar{X}) = 0$$

**A reta de regressão estimada passa pelo centro de gravidade  $(\bar{X}, \bar{Y})$  no diagrama de dispersão  $(X_i, Y_i)$ .**

$$\hat{\beta}_0 - \hat{\beta}_1 \bar{X} = (\bar{Y} - \hat{\beta}_1 \bar{X}) + \hat{\beta}_1 \bar{X} = \bar{Y}$$

$$\sum_{i=1}^n X_i \cdot e_i = 0$$

$$\begin{aligned} \sum_{i=1}^n X_i e_i &= \sum_{i=1}^n X_i (Y_i - \hat{Y}_i) = \sum_{i=1}^n X_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) \\ &= \sum_{i=1}^n X_i (Y_i - (\bar{Y} - \hat{\beta}_1 \bar{X}) - \hat{\beta}_1 X_i) \end{aligned}$$

Reorganizando e tirando fator comum

$$\begin{aligned} &= \sum_{i=1}^n X_i ((Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X})) \\ &= \sum_{i=1}^n X_i ((Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X})) \\ &= \sum_{i=1}^n X_i (Y_i - \bar{Y}) - \hat{\beta}_1 \sum_{i=1}^n X_i (X_i - \bar{X}) \end{aligned}$$

Vale notar de que no caso de centralizarmos (subtrair a media centralizando em torno do 0)  $X_i$  temos:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n X_i (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

podemos chegar a seguinte formula e substituir na conta:

$$\begin{aligned} \sum_{i=1}^n X_i (Y_i - \bar{Y}) &= \hat{\beta}_1 \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \hat{\beta}_1 \sum_{i=1}^n (X_i - \bar{X})^2 - \hat{\beta}_1 \sum_{i=1}^n X_i (X_i - \bar{X}) \\ &= \hat{\beta}_1 \sum_{i=1}^n [(X_i - \bar{X})^2 - X_i (X_i - \bar{X})] \\ &= \hat{\beta}_1 \sum_{i=1}^n [X_i^2 - 2X_i \bar{X} + \bar{X}^2 - X_i^2 + X_i \bar{X}] \\ &= \hat{\beta}_1 \sum_{i=1}^n [\bar{X}^2 - X_i \bar{X}] \\ &= \bar{X} \hat{\beta}_1 \sum_{i=1}^n (\bar{X} - X_i) = 0 \end{aligned}$$

$$\sum_{i=1}^n Y_i \cdot e_i = 0$$

$$\sum_{i=1}^n Y_i \cdot e_i = 0$$

$$\sum_{i=1}^n Y_i \cdot (Y_i - \hat{Y}_i) = 0$$

$$\sum_{i=1}^n Y_i Y_i - Y_i \hat{Y}_i = 0$$

$$\sum_{i=1}^n Y_i^2 - Y_i \hat{Y}_i = 0$$

$$\sum_{i=1}^n Y_i^2 - (\beta_0 + \beta_1 \cdot X_i)(\hat{\beta}_0 + \hat{\beta}_1 \cdot X_i) = 0$$

$$\sum_{i=1}^n Y_i^2 - (\hat{\beta}_0 \beta_0 + \beta_0 \hat{\beta}_1 X_i + \hat{\beta}_0 \beta_1 X_i + \beta_1 X_i \hat{\beta}_1 X_i) = 0$$

Como  $\hat{\beta}_0$  e  $\hat{\beta}_1$  são estimadores de  $\beta_0$  e  $\beta_1$  então você pode reorganizar a conta para ter os mesmos elementos de cada lado!

$$\sum_{i=1}^n Y_i^2 - \sum_{i=1}^n (\beta_0^2 + 2(\beta_0 \beta_1 X_i) + \beta_1^2 X_i^2) = 0$$

$$\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n (\beta_0^2 + 2(\beta_0 \beta_1 X_i) + \beta_1^2 X_i^2)$$

Sabemos que  $\beta_0^2 + 2(\beta_0 \beta_1 X_i) + \beta_1^2 X_i^2 = Y_i \hat{Y}_i$

$$\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n Y_i \hat{Y}_i$$